# Guía detallada de la implementación CI/CD para Azure Databricks

GitHub Actions, Terraform, seguridad y Declarative Automation Bundles

Documento didáctico del estado actual del repositorio

| | |
|---|---|
| Proyecto: | `proyecto-databricks-cicd` |
| Alcance actual: | Dev validado de extremo a extremo |
| Fecha de actualización: | 11 de octubre de 2026 |
| Presupuesto objetivo: | S/200 mensuales |

Este documento explica qué se creó, por qué existe cada pieza, cómo se validó y qué falta ejecutar.

# Índice

**1. Propósito y estado actual** **1**
1.1. Qué está implementado en el repositorio . . . 1
1.2. Hitos ya ejecutados . . . 1
1.3. Qué se hace manualmente y qué automatiza Terraform . . . 1

**2. Arquitectura y flujo general** **2**
2.1. Por qué se promueve el mismo SHA . . . 2

**3. Mapa del repositorio** **2**

**4. Python, entorno virtual y dependencias** **3**
4.1. Qué es un entorno virtual . . . 3
4.2. Qué contiene pyproject.toml . . . 3

**5. Validaciones de código y seguridad** **3**
5.1. Pruebas implementadas . . . 4
5.2. Qué ocurrió durante la validación real . . . 4

**6. Terraform desde cero** **5**
6.1. Conceptos esenciales . . . 5
6.2. Ciclo de comandos . . . 5
6.3. Por qué existen dos capas . . . 5
6.4. Backend remoto y archivos ignorados . . . 6
6.5. Validación efectuada . . . 6

**7. Infraestructura Azure definida** **6**

**8. Configuración Databricks definida** **6**

**9. GitHub Actions: validación del Pull Request** **7**
9.1. Jobs de CI . . . 7
9.2. Por qué el PR no posee secretos . . . 7

**10. GitHub Actions: despliegue Dev** **7**
10.1. Secuencia exacta del job . . . 7

**11. OIDC y mínimo privilegio** **8**

**12. Bundle, carpeta normal y smoke test** **8**
12.1. Debugging manual en Dev y QA . . . 8

**13. Flujo completo de un cambio** **9**

**14. Controles de costo** **9**

**15. Archivos de seguridad y reproducibilidad** **10**

15.1. .gitignore . . . . . 10

15.2. Lockfiles Terraform . . . . . 10

15.3. Dependabot . . . . . 10

**16. Qué significa "listo" en este punto** **10**

**17. Bitácora razonada de la sesión del 11 de octubre** **11**

17.1. Del state local al backend remoto . . . . . 11

17.2. Por qué participaron dos identidades . . . . . 11

17.3. Qué demostró el despliegue Dev . . . . . 11

17.4. Decisión QA persistente durante la fase . . . . . 11

**18. Ruta docente propuesta** **12**

**19. Glosario breve** **12**

**20. Próximo recorrido recomendado** **13**

# 1. Propósito y estado actual

El proyecto es un laboratorio profesional y progresivo para aprender a llevar código Python, SQL y notebooks desde GitHub hasta Azure Databricks. La primera meta no es desplegar de inmediato en tres entornos, sino demostrar de punta a punta el flujo hacia **Dev**, controlar los costos y recién después incorporar QA y Prod.

## 1.1. Qué está implementado en el repositorio

- Estructura de código Python, SQL, notebooks y pruebas.
- Configuración reproducible de herramientas de calidad y seguridad.
- Terraform para crear el workspace Azure Databricks Dev y su presupuesto.
- Terraform para configurar identidad OIDC, catálogo, esquema y permisos del workspace.
- Un Bundle que publica una carpeta normal y administra el Job de smoke test.
- Un workflow de validación de Pull Requests.
- Un workflow de despliegue automático hacia Dev después del merge a `main`.
- Documentación operativa, reglas de contribución y registros de decisiones arquitectónicas.

## 1.2. Hitos ya ejecutados

- Suscripción Pay-As-You-Go activa y budget mensual de USD 58 con alertas progresivas.
- Workspace Azure Databricks Dev creado en `eastus2` mediante Terraform.
- Configuración Databricks aplicada: grupo, usuario organizacional, service principal CI/CD, política OIDC, carpetas, permisos, catálogo administrado y esquema `cicd`.
- Repositorio GitHub público, rama `main` protegida y Environment `dev`.
- Pipeline real completado: PR, checks, merge, OIDC, Bundle, reconciliación y smoke test serverless.
- Prueba de drift e idempotencia: un archivo manual fue eliminado, uno modificado fue restaurado y el Job no se duplicó al redesplegar el mismo SHA.
- States Azure y Databricks migrados a blobs remotos separados, con bloqueo y versionado.
- Primer corte de costo de USD 1.96, luego actualizado a USD 2.42 en Cost Management.

QA y Prod aún no existen. QA se aprovisionará una vez y permanecerá durante una ventana controlada del laboratorio para practicar release candidates y pruebas repetibles. No se creará por cada PR y se destruirá al cerrar la fase QA o si el forecast amenaza el budget. Prod sólo se diseñará después de validar QA y medir el costo conjunto.

## 1.3. Qué se hace manualmente y qué automatiza Terraform

La persona propietaria crea la cuenta Microsoft/Azure, activa MFA, registra facturación, convierte la suscripción gratuita a Pay-As-You-Go, acepta términos, selecciona la suscripción mediante Azure CLI y autoriza cada `apply`. Son decisiones de identidad y facturación que no deben delegarse a un pipeline.

Después de ese bootstrap, Terraform creó el Resource Group, workspace Dev, identidad y permisos. El budget inicial se creó manualmente y Terraform lo reconoce como una frontera operativa para no

duplicarlo. Terraform tampoco despliega cada notebook: los Bundles administran código y Jobs con una cadencia mucho mayor que la infraestructura.

## 2. Arquitectura y flujo general

El flujo elegido combina integración continua sobre `main` con promoción de commits inmutables. `main` representa código integrado; no representa automáticamente la versión de Producción.

```
feature/* o fix/*
       |
       | Pull Request: calidad, pruebas y seguridad
       v
     main ---- despliegue automatico ----> Dev
       |
       | tag vX.Y.Z-rc.N
       v
      QA ---- pruebas + aprobacion ----> mismo SHA
       |
       | tag final vX.Y.Z
       v
     Prod
```

Si un release candidate falla en QA, Prod continúa usando la versión estable anterior. La corrección se hace en una nueva rama `fix/*`, se integra mediante otro PR y genera un nuevo SHA y un nuevo candidato. No se mueve ni se reutiliza el tag fallido.

### 2.1. Por qué se promueve el mismo SHA

Un **SHA** identifica de forma única un commit Git. Promover el mismo SHA reduce la pregunta "¿QA probó exactamente lo que llegó a Prod?" a una comparación verificable. No se recompila ni se edita el código durante la promoción.

## 3. Mapa del repositorio

| Ruta | Responsabilidad |
|---|---|
| `src/databricks_cicd/` | Código Python reutilizable y contrato de configuración por entorno. |
| `tests/` | Pruebas unitarias ejecutadas con Pytest. |
| `sql/` | SQL versionado y validado con dialecto Databricks. |
| `proyecto_test/` | Árbol de notebooks y configuración reflejado en el workspace. |
| `resources/` | Jobs y otros recursos declarados por el Bundle. |
| `databricks.yml` | Targets, rutas y variables del Bundle. |
| `scripts/` | Utilidades del pipeline, como validación de variables requeridas. |
| `infra/azure/dev/` | Recursos Azure: presupuesto, resource group y workspace Dev. |
| `infra/databricks/dev/` | Configuración interna de Databricks después de crear el workspace. |
| `infra/modules/` | Módulos Terraform reutilizables. |
| `.github/workflows/` | CI de Pull Requests y despliegue Dev. |

| Ruta | Responsabilidad |
|---|---|
| `docs/adr/` | Decisiones de arquitectura y sus motivos. |
| `pyproject.toml` | Metadatos Python, dependencias de desarrollo y configuración de herramientas. |
| `.gitignore` | Evita versionar state, variables locales, entornos virtuales y credenciales. |

# 4. Python, entorno virtual y dependencias

## 4.1. Qué es un entorno virtual

Un **entorno virtual** o `venv` es una carpeta aislada que contiene un intérprete de Python y sus paquetes. Evita mezclar dependencias del proyecto con paquetes globales del equipo.

Durante la implementación se creó localmente `.venv/` y se instalaron las dependencias de desarrollo declaradas en `pyproject.toml`. La carpeta está ignorada por Git porque:

- puede reconstruirse a partir de la configuración;
- cambia entre Windows, Linux y macOS;
- versionarla añadiría miles de archivos ajenos al código del proyecto.

El proceso conceptual fue:

```
python -m venv .venv
.venv/Scripts/python -m pip install --editable ".[dev]"
```

`-editable` instala el proyecto apuntando a la carpeta de trabajo. Así, los cambios en `src/` se reflejan sin reinstalar el paquete. El extra `[dev]` instala únicamente las herramientas necesarias para desarrollar y validar.

## 4.2. Qué contiene pyproject.toml

`pyproject.toml` centraliza:

- nombre, versión y versión mínima de Python;
- sistema de construcción basado en Setuptools;
- dependencias de desarrollo;
- configuración de Pytest, Ruff y Bandit;
- ubicación del paquete dentro de `src/`.

Las dependencias de validación incluyen Ruff, Pytest, SQLFluff, Yamllint, Bandit, `detect-secrets` y `pip-audit`. No son servicios cloud: son programas ejecutados en el equipo local o en un runner de GitHub Actions.

# 5. Validaciones de código y seguridad

| Herramienta | Qué valida | Qué evita |
|---|---|---|
| Ruff | Estilo, imports, errores Python y formato. | Código inconsistente, imports sin usar y defectos simples. |
| Pytest | Comportamiento esperado mediante pruebas. | Cambios que rompen reglas ya verificadas. |
| SQLFluff | Sintaxis y estilo SQL con dialecto Databricks. | SQL difícil de revisar o incompatible con las reglas elegidas. |
| Yamllint | Estructura y estilo de archivos YAML. | Workflows mal indentados o configuración ambigua. |
| Bandit | Análisis estático de seguridad para Python. | Patrones inseguros conocidos dentro del código. |
| detect-secrets | Patrones y entropía compatibles con secretos. | Tokens o claves enviados accidentalmente a Git. |
| pip-audit | Vulnerabilidades publicadas de dependencias. | Usar versiones con CVE o avisos de seguridad conocidos. |
| Terraform validate | Sintaxis, tipos y relaciones de configuración. | Planes inválidos antes de contactar Azure. |

### 5.1. Pruebas implementadas

El módulo `config.py` modela tres valores obligatorios: entorno, catálogo y esquema. Las pruebas verifican que:

1. una configuración Dev válida se normalice correctamente;
2. una variable ausente cause un error explícito;
3. un entorno distinto de Dev, QA o Prod sea rechazado.

Este patrón mueve errores de configuración hacia el inicio del pipeline. Es preferible fallar antes de autenticarse o modificar Databricks que descubrir el problema a mitad del despliegue.

### 5.2. Qué ocurrió durante la validación real

La primera ejecución no fue artificialmente perfecta. Encontró:

- imports Python sin normalizar;
- archivos que Ruff deseaba reformatear;
- Yamllint intentando revisar el contenido de `.venv`;
- un salto de línea SQL incorrecto;
- versiones de `pip`, Pytest y SQLFluff reportadas con vulnerabilidades conocidas.

Las correcciones fueron: ordenar y formatear Python, excluir `.venv` del lint YAML, corregir el SQL, actualizar los rangos de dependencias y repetir todas las validaciones. El resultado final fue:

- trece pruebas unitarias aprobadas;
- Ruff, SQLFluff y Yamllint aprobados;
- Bandit sin incidencias;

- detección de secretos aprobada;
- `pip-audit` sin vulnerabilidades conocidas en las dependencias auditables.

Esto ilustra el propósito de CI: convertir problemas reproducibles en feedback antes del merge.

# 6. Terraform desde cero

## 6.1. Conceptos esenciales

**Provider**
Plugin que traduce Terraform a la API de una plataforma. Aquí se usan AzureRM y Databricks.

**Resource**
Objeto que Terraform crea o administra, por ejemplo un resource group o catálogo.

**Variable**
Entrada configurable; evita codificar IDs o valores de entorno dentro de los recursos.

**Output**
Dato producido por una capa para uso humano o para configurar la siguiente.

**Module**
Conjunto reutilizable de recursos con entradas y salidas.

**State**
Registro que vincula la configuración con recursos reales. Puede contener datos sensibles.

**Lockfile**
Archivo que fija las versiones exactas de providers y sus hashes.

## 6.2. Ciclo de comandos

```
terraform init
terraform fmt -check
terraform validate
terraform plan -out=tfplan
terraform apply tfplan
```

`init` prepara providers; `fmt` revisa formato; `validate` comprueba la configuración; `plan` muestra cambios propuestos; `apply` ejecuta exactamente el plan. Sólo los dos últimos requieren valores y permisos cloud reales, y sólo `apply` crea o modifica recursos.

## 6.3. Por qué existen dos capas

**Capa Azure:** crea el contenedor cloud y el workspace. Incluye el presupuesto y etiquetas de costos. Usa el provider AzureRM.

**Capa Databricks:** se ejecuta cuando el workspace ya responde. Crea la identidad Databricks, política OIDC, permisos, catálogo, esquema, carpeta del proyecto y ruta protegida para el estado del Bundle. Usa providers Databricks a nivel de cuenta y workspace.

Separarlas evita intentar configurar una API que todavía no existe y permite destruir primero los objetos internos, y luego el workspace.

### 6.4. Backend remoto y archivos ignorados

Los states comenzaron locales para facilitar el aprendizaje y luego se migraron a un contenedor privado Azure Storage. Azure Dev usa `dev/azure.tfstate`; Databricks Dev usa `dev/databricks.tfstate`. Separar claves conserva ciclos de vida y radios de impacto distintos.

El backend usa Microsoft Entra, no Storage keys ni SAS. Tiene versionado, retención de 14 días y bloqueo nativo. La cuenta personal opera la capa Azure; el usuario organizacional opera Databricks. Ambos accesos están declarados mediante RBAC. Los patrones `*.tfstate`, `*.tfvars`, `*.tfplan` y `*.tfbackend` permanecen ignorados. El state nunca debe pegarse en tickets ni enviarse por correo.

### 6.5. Validación efectuada

Se descargó Terraform 1.13.4 con verificación SHA-256. Antes de crear recursos se ejecutaron `fmt`, `init -backend=false`, `validate` y `plan`. Cada `apply` utilizó un plan guardado y una autorización humana explícita. Después de la migración, los planes de Azure Dev y Databricks Dev devolvieron `No changes`, demostrando que mover el state no cambió la infraestructura. Los providers quedaron fijados por lockfiles.

## 7. Infraestructura Azure definida

La capa Azure declara:

- un resource group para Dev;
- un workspace Azure Databricks Premium;
- un managed resource group con nombre controlado;
- etiquetas `project`, `environment`, `owner` y `managed_by`;
- integración opcional con budget, desactivada porque el budget inicial ya existe en Azure.

Azure Budgets alerta, pero no corta el consumo. Además, el importe está expresado en la moneda de facturación de la suscripción, no necesariamente en soles. Se configuraron USD 58 como objetivo operativo aproximado para S/200.

## 8. Configuración Databricks definida

La segunda capa declara:

- un service principal exclusivo para CI/CD Dev;
- asignación del principal al workspace con rol de usuario, no administrador;
- una política de federación OIDC limitada al repositorio y GitHub Environment `dev`;
- la carpeta normal `/Workspace/data/proyecto_test`;
- la ruta protegida `/Workspace/.cicd/proyecto_test/dev`;
- `CAN_MANAGE` para CI/CD y edición temporal para desarrolladores en Dev;
- catálogo administrado del workspace y esquema `cicd`;
- permisos de datos específicos para la identidad del pipeline.

El catálogo y el esquema usan `force_destroy = false`. Si contienen datos, Terraform debe negarse a eliminarlos automáticamente. Es una barrera contra destrucción accidental.

# 9. GitHub Actions: validación del Pull Request

El workflow `validate-pr.yml` se dispara ante un PR hacia `main` o manualmente. Declara `contents: read` y no recibe credenciales cloud.

## 9.1. Jobs de CI

1. **Python, SQL and YAML**: instala el proyecto y ejecuta Ruff, SQLFluff, Yamllint y Pytest.
2. **Security checks**: ejecuta detección de secretos, Bandit y `pip-audit`.
3. **Terraform static validation**: revisa formato, inicializa sin backend y valida ambas capas.

Los jobs usan `timeout-minutes`; la concurrencia cancela validaciones antiguas del mismo PR. Las acciones principales están fijadas a SHA completos con un comentario que indica la versión legible.

## 9.2. Por qué el PR no posee secretos

Un contribuidor podría modificar el código que ejecuta CI. Entregar credenciales a ese proceso permitiría exfiltrarlas. Por eso la validación de PR sólo analiza código y no usa `id-token: write`, tokens Databricks ni secretos de Azure.

# 10. GitHub Actions: despliegue Dev

`deploy-dev.yml` se ejecuta después de un push a `main`, normalmente producido por un merge aprobado. Usa el GitHub Environment `dev` y declara sólo:

```
permissions:
  contents: read
  id-token: write
```

`id-token: write` no da permisos generales de escritura en GitHub. Permite pedir un token OIDC temporal que Databricks validará contra la política configurada.

El evento `push` usa filtros de rutas. Un merge puramente documental sigue pasando CI, pero no solicita identidad OIDC, no despliega el Bundle y no inicia el smoke test. Sólo disparan CD los cambios en `proyecto_test/`, `resources/`, `scripts/`, `databricks.yml` o los workflows de despliegue. `workflow_dispatch` permanece disponible para una prueba manual.

## 10.1. Secuencia exacta del job

1. Descarga exactamente `github.sha`.
2. Valida variables obligatorias sin imprimir sus valores.
3. Instala la CLI oficial con `databricks/setup-cli`.
4. Comprueba la identidad OIDC mediante `databricks current-user me`.
5. Valida y despliega el Bundle parametrizado con `github.sha`.

6. Reconcilia rutas, tipos y hashes contra un manifiesto del repositorio.
7. Elimina archivos manuales y restaura contenido modificado o eliminado.
8. Ejecuta el Job serverless de humo declarado por el Bundle.
9. Escribe un resumen con commit, ruta y entorno, sin secretos.

La concurrencia `databricks-dev` impide dos despliegues simultáneos. El Bundle conserva una identidad de despliegue y una segunda ejecución del mismo SHA debe producir el mismo estado.

## 11. OIDC y mínimo privilegio

**OIDC** permite que GitHub demuestre ante Databricks qué repositorio y environment ejecutan el job. Databricks intercambia esa prueba por una credencial temporal. No existe un PAT de larga duración guardado en GitHub.

La política acepta un subject similar a:

```
repo:OWNER/REPOSITORY:environment:dev
```

Si el repositorio se renombra, transfiere o intenta usar otro environment, la autenticación falla. Es un control positivo, no un inconveniente.

El service principal no es workspace admin. Sólo recibe acceso al workspace, a la carpeta del proyecto, al estado del Bundle y al catálogo necesarios. QA y Prod tendrán identidades diferentes.

## 12. Bundle, carpeta normal y smoke test

El árbol local `proyecto_test/` se publica bajo `/Workspace/data/proyecto_test`. No aparece como Git Folder. El archivo `databricks.yml` define targets y rutas; `resources/` define Jobs. El estado técnico vive fuera de la carpeta editable, bajo `/Workspace/.cicd`.

Un manifiesto calcula la ruta remota, tipo y SHA-256 de cada archivo. Después de desplegar, el pipeline elimina objetos desconocidos y compara el contenido exportado. Sus guardas rechazan rutas amplias como `/Workspace` o `/Workspace/data`; sólo puede limpiar la carpeta exacta del proyecto.

El smoke test es deliberadamente pequeño:

```
result = spark.sql("SELECT 1 AS pipeline_is_healthy").first()
assert result.pipeline_is_healthy == 1
```

No prueba toda la lógica del proyecto. Confirma que autenticación, Bundle, reconciliación, lectura del notebook y cómputo serverless funcionan juntos. Las pruebas de negocio crecerán después sin usar datos reales.

### 12.1. Debugging manual en Dev y QA

Los desarrolladores pueden modificar archivos y notebooks en Dev y QA para diagnosticar. Esos cambios son temporales: deben copiarse a una rama y pasar por PR. El siguiente despliegue restaura lo que existe en Git, recrea eliminados y borra agregados manualmente. No existe sincronización automática workspace a Git. Prod permanece sin edición manual para desarrolladores.

## 13. Flujo completo de un cambio

1. El desarrollador crea `feature/descripcion` desde `main`.
2. Trabaja localmente dentro de `.venv` y ejecuta linters y pruebas.
3. Abre un PR a `main`.
4. GitHub ejecuta calidad, seguridad y Terraform sin credenciales cloud.
5. Una revisión humana aprueba y se realiza squash merge.
6. El push resultante a `main` inicia el workflow Dev.
7. OIDC entrega una identidad temporal de mínimo privilegio.
8. Databricks despliega el Bundle y reconcilia la carpeta contra el SHA.
9. Se ejecuta el smoke test serverless.
10. El resultado y el SHA quedan registrados en GitHub Actions.

En la fase futura, un tag `v0.1.0-rc.1` seleccionará un SHA para QA. Si pasa, el tag final `v0.1.0` apuntará al mismo SHA y será elegible para Prod.

## 14. Controles de costo

La estrategia para acercarse a S/200 mensuales es:

- crear sólo Dev al inicio;
- usar serverless o cómputo efímero;
- no mantener clústeres clásicos permanentes;
- revisar costos y forecast después de cada práctica;
- usar alertas progresivas;
- destruir el laboratorio si aparece gasto inesperado;
- crear QA y Prod sólo cuando exista una prueba que justifique su costo.

La consulta real de Cost Management del 11 de octubre mostró:

| **Servicio** | **Resource Group** | **Costo USD** |
|---|---|---|
| NAT Gateway | `rg-databricks-cicd-dev-managed` | 1.76 |
| Virtual Network | `rg-databricks-cicd-dev-managed` | 0.20 |
| Storage | `rg-databricks-cicd-dev-managed` | 0.00 |
| **Total visible** | | **1.96** |

El hallazgo importante no es el total pequeño, sino su causa. Secure Cluster Connectivity crea un NAT Gateway en la red administrada del workspace. Ese recurso genera costo base aunque no haya clústeres clásicos activos. Duplicar workspaces permanentes puede duplicar este componente antes de ejecutar pruebas. Un corte posterior mostró USD 2.42 acumulados. QA se conservará durante una ventana corta de prácticas, con revisión frecuente de Cost Analysis y una fecha de teardown; no se crea por PR.

El orden seguro de destrucción es configuración Databricks primero y capa Azure después. Siempre se revisa `terraform plan -destroy` antes de aplicar la destrucción.

# 15. Archivos de seguridad y reproducibilidad

## 15.1. .gitignore

Excluye `.venv`, caches, archivos `.env`, certificados, `terraform.tfvars`, planes y states. Mantiene versionados los ejemplos sin credenciales.

## 15.2. Lockfiles Terraform

Los archivos `.terraform.lock.hcl` registran provider, versión seleccionada y hashes. Sí deben versionarse: permiten que CI y otros equipos utilicen la misma versión validada.

## 15.3. Dependabot

Revisa semanalmente dependencias Python, GitHub Actions y providers Terraform. Una actualización no se aplica directamente: genera un PR que debe pasar por los mismos checks.

# 16. Qué significa "listo" en este punto

**Dev aceptado de extremo a extremo**

- infraestructura Azure y gobierno Databricks administrados por Terraform;
- validación de PR y despliegue Dev funcionando en GitHub Actions;
- autenticación OIDC sin secretos persistentes;
- carpeta del workspace reconciliada contra el SHA de Git;
- smoke test serverless e idempotencia comprobados;
- states remotos separados, bloqueados y versionados;
- cero runs activos, cero clústeres y warehouse serverless detenido.

**Siguiente fase**

- declarar QA en Terraform sin aplicarlo todavía;
- crear GitHub Environment `qa` con identidad propia;
- promover tags `vX.Y.Z-rc.N` al mismo SHA validado en Dev;
- crear QA una vez, repetir pruebas durante una ventana controlada y registrar evidencia;
- medir el costo conjunto y destruir QA al cerrar la fase antes de diseñar Prod.

# 17. Bitácora razonada de la sesión del 11 de octubre

## 17.1. Del state local al backend remoto

El problema era de continuidad y concurrencia. Un state local depende de un solo equipo y no puede bloquear a dos operadores. La solución fue una pila bootstrap que creó un Storage Account `Standard_LRS`, un contenedor privado, versionado y retención. El bootstrap conserva un state local mínimo porque el backend no puede existir antes de ser creado.

La migración se ejecutó una capa a la vez. Terraform confirmó state local existente y destino vacío, copió el contenido y después se verificaron `state list`, tamaño del blob y `plan`.

| Capa | Blob | Resultado |
|---|---|---|
| Azure Dev | `dev/azure.tfstate` | 7,412 bytes; `No changes` |
| Databricks Dev | `dev/databricks.tfstate` | 24,218 bytes; `No changes` |

**Causa y consecuencia:** si se hubiera elegido "no" al prompt de copia, Terraform habría iniciado con state vacío y podría haber propuesto recrear recursos existentes. Por eso se creó primero un respaldo local y sólo se respondió "yes" después de confirmar que el blob remoto estaba vacío.

## 17.2. Por qué participaron dos identidades

La cuenta personal es propietaria de la suscripción Azure. El usuario organizacional puede administrar la cuenta Databricks. El backend se abre antes de que el provider consulte recursos, por lo que ambos operadores necesitaban acceso de datos al contenedor. Terraform declaró un `Storage Blob Data Contributor` para cada Object ID, limitado al contenedor.

No se compartieron contraseñas ni se concedió Global Administrator. El principio es separar funciones: la identidad apropiada para facturación e infraestructura no tiene por qué ser la misma que gobierna Databricks.

## 17.3. Qué demostró el despliegue Dev

El despliegue exitoso no se redujo a copiar archivos. Demostró en conjunto:

1. GitHub emitió un token OIDC para el repositorio y Environment correctos.
2. Databricks reconoció al service principal con `workspace_access` mínimo.
3. El Bundle publicó el SHA exacto en una carpeta normal del workspace.
4. La reconciliación comparó rutas, tipos y hashes.
5. El smoke test inició cómputo serverless, ejecutó Spark y terminó correctamente.
6. Una segunda ejecución restauró drift y no duplicó el Job.

Después del último merge se comprobó cero runs activos, cero clústeres y el Serverless Starter Warehouse en estado `STOPPED` con cero clústeres.

## 17.4. Decisión QA persistente durante la fase

La seguridad recomienda workspaces separados y, en plataformas empresariales, normalmente permanentes. El presupuesto educativo obliga a limitar el tiempo: el costo observado provino

principalmente del NAT Gateway administrado, no del notebook de humo. Mantener QA todo el mes puede consumir una parte sustancial del budget aun cuando nadie lo use.

La primera decisión fue crear y destruir QA por release candidate. Se reemplazó al observar que eso añadía latencia y enseñaba menos sobre operación repetible. QA se creará una sola vez para la fase, recibirá varios candidatos y se destruirá al terminar o si el forecast amenaza el budget. Un PR sólo ejecuta CI sin credenciales cloud. En un entorno bancario real, QA suele permanecer por disponibilidad, integraciones y gobierno.

## 18. Ruta docente propuesta

El proyecto se estudiará en módulos cortos. Cada módulo combinará teoría, lectura de archivos, ejercicio, fallo controlado y preguntas de comprobación:

| Módulo | Tema | Práctica |
|---|---|---|
| 1 | Git y promoción inmutable | Ramas, PR, SHA, tag RC y tag final. |
| 2 | CI y calidad | Ruff, Pytest, SQLFluff, SAST, SCA y secret scanning. |
| 3 | Terraform | Provider, resource, state, plan, apply, drift y destroy. |
| 4 | Azure e identidad | Tenant, suscripción, Entra, RBAC y mínimo privilegio. |
| 5 | Databricks | Workspace, Unity Catalog, Bundles, Jobs y serverless. |
| 6 | OIDC | Claims, subject, audience, federación y ausencia de secretos. |
| 7 | CD e idempotencia | Manifiesto, reconciliación, smoke test y rollback. |
| 8 | Costos | Budget, costo fijo, costo variable, forecast y teardown. |
| 9 | QA controlado | Release candidates, pruebas repetibles, costos y teardown. |
| 10 | Prod | Aprobaciones, segregación de funciones y recuperación. |

Para cada acción futura se explicarán cuatro preguntas: **qué hace**, **por qué se hace**, **qué riesgo controla** y **qué ocurriría si se omite**. Así el repositorio funciona a la vez como laboratorio técnico y material de estudio acumulativo.

## 19. Glosario breve

**CI** Integración continua: validación automática de cada cambio.

**CD**
Entrega o despliegue continuo: promoción automatizada y controlada.

**Runner**
Máquina efímera donde GitHub ejecuta un job.

**Workflow**
Archivo YAML que define eventos y jobs de GitHub Actions.

**Environment**
Frontera GitHub para variables, secretos y aprobaciones de un entorno.

**Service principal**
Identidad no humana usada por automatización.

**OIDC**
Federación que proporciona credenciales temporales sin secreto persistente.

**SAST**
Análisis estático de seguridad del código.

**SCA**
Análisis de vulnerabilidades de dependencias.

**Idempotencia**
Repetir una operación produce el mismo estado, sin duplicados.

**Smoke test**
Prueba pequeña que confirma que el camino crítico funciona.

**Unity Catalog**
Capa de gobierno y permisos para datos y objetos Databricks.

**Release candidate**
Versión candidata para QA, todavía no productiva.

## 20. Próximo recorrido recomendado

1. Diseñar las capas Azure y Databricks de QA reutilizando módulos, sin ejecutar `apply`.
2. Añadir identidad OIDC y GitHub Environment exclusivos para QA.
3. Implementar promoción mediante tags `v0.1.0-rc.N` sobre un SHA de `main`.
4. Revisar el plan de creación y autorizar un único aprovisionamiento de QA.
5. Ejecutar varias promociones durante una ventana controlada y medir su costo real.
6. Destruir QA en orden seguro al cerrar la fase y confirmar que no quedan recursos huérfanos.
7. Convertir cada fase completada en una lección teórica y práctica.

**Principio rector: entender cada cambio antes de automatizarlo.**